第 11 关、协程

1、协程

协程指的是单线程下的并发，又称微线程，协程是一种用户态的轻量级线程，即协程是由用户程序自己控制调度的。

（1）异步：在一个任务未完成时，就可以执行其他多个任务，彼此不受影响；

（2）同步：一个任务结束才能启动下一个。

2、多协程

每台计算机都靠着CPU（中央处理器）干活。在过去，单核CPU的计算机在处理多任务时，会出现一个问题：每个任务都要抢占CPU，执行完了一个任务才开启下一个任务。CPU

毕竟只有一个，这会让计算机处理的效率很低。

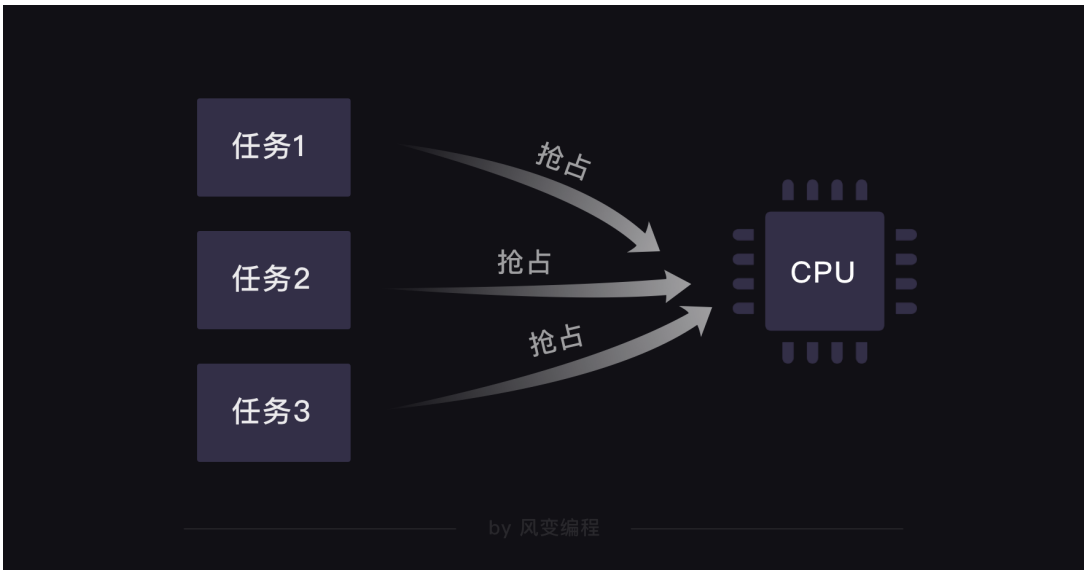

为了解决这样的问题，一种非抢占式的异步技术被创造了出来，这种方式叫多协程（在此，多是多个的意思）

1-1、gevent 库

1-1-1、安装 gevent

```
window电脑：在终端输入命令：pip install gevent，按下enter键；
mac电脑：在终端输入命令：pip3 install gevent，按下enter键
```

1-1-2、gevent 使用

```
from gevent import monkey
#从gevent库里导入monkey模块。
monkey.patch_all()
#monkey.patch_all()能把程序变成协作式运行，就是可以帮助程序实现异步。
import gevent,time,requests
#导入gevent、time、requests。

start = time.time()
#记录程序开始时间。

url_list = ['https://www.baidu.com/',
'https://www.sina.com.cn/',
'http://www.sohu.com/',
'https://www.qq.com/',
'https://www.163.com/',
'http://www.iqiyi.com/',
'https://www.tmall.com/',
'http://www.ifeng.com/']
#把8个网站封装成列表。

def crawler(url):
#定义一个crawler()函数。
    r = requests.get(url)
```

```
    #用requests.get()函数爬取网站。
    print(url,time.time()-start,r.status_code)
    #打印网址、请求运行时间、状态码。

tasks_list = [ ]
#创建空的任务列表。

for url in url_list:
#遍历url_list。
    task = gevent.spawn(crawler,url)
    #用gevent.spawn()函数创建任务。
    tasks_list.append(task)
    #往任务列表添加任务。
gevent.joinall(tasks_list)
#执行任务列表里的所有任务，就是让爬虫开始爬取网站。
end = time.time()
#记录程序结束时间。
print(end-start)
#打印程序最终所需时间。
```

- 第 1、3 行代码：从 gevent 库里导入了 monkey 模块，这个模块能将程序转换成可异步的程序。monkey.patch_all() 能给程序打上补丁，让程序变成是异步模式，而不是同步模式（我们要在导入其他库和模块前，先把 monkey 模块导入进来，并运行 monkey.patch_all()。这样，才能先给程序打上补丁。可以理解成这是一个规范的写法）；
- 第 5 行代码：我们导入了 gevent 库来帮我们实现多协程，导入了 time 模块来帮我们记录爬取所需时间，导入了 requests 模块帮我们实现爬取8个网站；
- 第 21、23、25 行代码：我们定义了一个 crawler 函数，只要调用这个函数，它就会执行【用 requests.get() 爬取网站】和【打印网址、请求运行时间、状态码】这两个任务；
- 第 33 行代码：因为 gevent 只能处理 gevent 的任务对象，不能直接调用普通函数，所以需要借助 gevent.spawn() 来创建任务对象（注意：gevent.spawn() 的参数需为要调用的函数名及该函数的参数。比如，gevent.spawn(crawler,url) 就是创建一个执行 crawler 函数的任务，参数为 crawler 函数名和它自身的参数 url）；

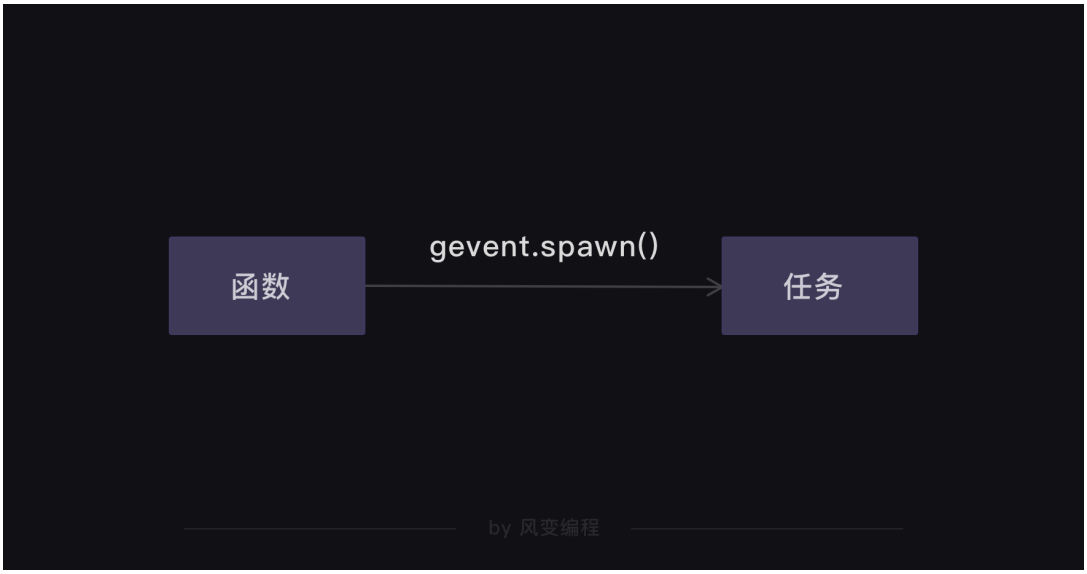

- 第 35 行代码：用 append 函数把任务添加到 tasks_list 的任务列表里；
- 第 37 行代码：调用 gevent 库里的 joinall 方法，能启动执行所有的任务。gevent.joinall(tasks_list) 就是执行 tasks_list 这个任务列表里的所有任务，开始爬取。

1-2、queue 模块

queue 翻译成中文是队列的意思。我们可以用 queue 模块来存储任务，让任务都变成一条整齐的队列，就像银行窗口的排号做法。因为 queue 其实是一种有序的数据结构，可以用来存取数据。

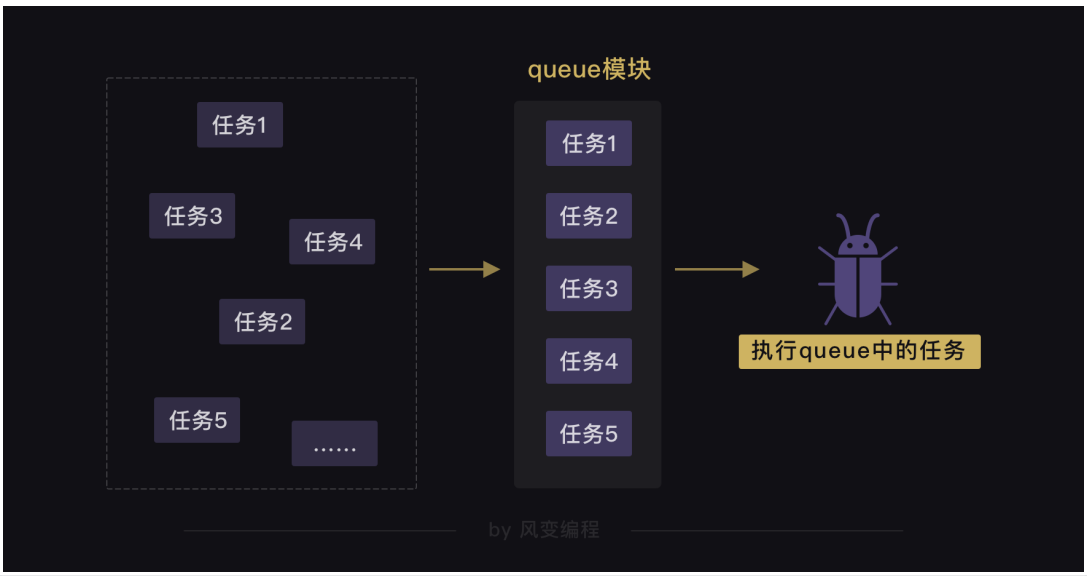


```
from gevent import monkey
monkey.patch_all()
import gevent,time,requests
from gevent.queue import Queue

start = time.time()

url_list = ['https://www.baidu.com/',
'https://www.sina.com.cn/',
'http://www.sohu.com/',
'https://www.qq.com/',
'https://www.163.com/',
'http://www.iqiyi.com/',
'https://www.tmall.com/',
'http://www.ifeng.com/']

```

```
work = Queue()
for url in url_list:
    work.put_nowait(url)

def crawler():
    while not work.empty():
        url = work.get_nowait()
        r = requests.get(url)
        print(url,work.qsize(),r.status_code)

tasks_list  = [ ]

for x in range(2):
    task = gevent.spawn(crawler)
    tasks_list.append(task)
gevent.joinall(tasks_list)

end = time.time()
print(end-start)
```

1-2-1、导入模块

```
from gevent import monkey
#从gevent库里导入monkey模块。
monkey.patch_all()
#monkey.patch_all()能把程序变成协作式运行，就是可以帮助程序实现异步。
import gevent,time,requests
#导入gevent、time、requests
from gevent.queue import Queue
#从gevent库里导入queue模块
```

1-2-2、创建队列，并往队列存入数据

```
start = time.time()
#记录程序开始时间

url_list = ['https://www.baidu.com/',
'https://www.sina.com.cn/',
'http://www.sohu.com/',
'https://www.qq.com/',
'https://www.163.com/',
'http://www.iqiyi.com/',
'https://www.tmall.com/',
'http://www.ifeng.com/']

work = Queue()
#创建队列对象，并赋值给work。
for url in url_list:
#遍历url_list
    work.put_nowait(url)
    #用put_nowait()函数可以把网址都放进队列里。
```

1-2-3、定义爬取函数

```
def crawler():
    while not work.empty():
    #当队列不是空的时候，就执行下面的程序。
        url = work.get_nowait()
        #用get_nowait()函数可以把队列里的网址都取出。
        r = requests.get(url)
        #用requests.get()函数抓取网址。
        print(url,work.qsize(),r.status_code)
        #打印网址、队列长度、抓取请求的状态码。
```

- empty 方法，是用来判断队列是不是空了的；
- get_nowait 方法，是用来从队列里提取数据的；
- qsize 方法，是用来判断队列里还剩多少数量的。